

Análise Comparativa com Base nos Resultados Obtidos

A análise dos resultados experimentais permite uma avaliação mais concreta do comportamento dos dois métodos, considerando especificamente os campos nome, RG e RA, conforme extraídos dos atestados processados.

Com base nos dados gerados pelo sistema, observa-se que o método de OCR com Tesseract, aliado ao uso de expressões regulares, apresentou desempenho consistente e preciso na extração dos três campos em todos os documentos analisados. Em todos os casos, o nome do aluno, o RG e o RA foram corretamente identificados e estruturados, sem inconsistências ou erros de formatação. Isso indica que, para documentos com padrão textual estável, o OCR combinado com regras bem definidas apresenta alto grau de confiabilidade.

Em contraste, o modelo Donut apresentou comportamento distinto entre os diferentes tipos de dados. Para os campos numéricos, especificamente RG e RA, o modelo demonstrou boa capacidade de extração, retornando valores corretos em todos os casos analisados. Isso sugere que o modelo consegue localizar e interpretar padrões numéricos relevantes dentro do documento, ainda que não preserve necessariamente a formatação original em outros contextos.

Entretanto, a principal limitação do Donut foi observada na extração do nome do aluno. Em todos os documentos analisados, o campo correspondente ao nome retornado pelo modelo apresentou erro. Em vez de fornecer exclusivamente o nome, o modelo incluiu partes da própria pergunta no resultado, como “What is the full name of the student?”, seguido de termos irrelevantes extraídos do documento, como “matricula” ou “universidade”. Esse comportamento evidencia que o modelo não isolou corretamente a informação solicitada, mas sim gerou uma resposta contaminada pelo prompt utilizado.

Esse padrão de erro foi consistente nos três casos analisados, indicando não se tratar de uma falha pontual, mas de uma limitação estrutural do uso do modelo nesse contexto específico. O problema não está relacionado à ausência da informação no documento, mas à forma como o modelo interpreta e responde à pergunta, misturando instrução e conteúdo.

Dessa forma, ao comparar os dois métodos com base nos resultados obtidos, observa-se que o OCR apresentou acerto total nos três campos avaliados, enquanto o Donut apresentou acerto parcial, sendo eficaz para dados numéricos, mas falho na extração de dados textuais mais complexos, como o nome do aluno.

Essa diferença reforça a natureza dos métodos. O OCR, por operar de forma determinística e baseado em padrões explícitos, tende a apresentar maior precisão em cenários controlados e estruturados. Já o Donut, por depender de inferência baseada em aprendizado prévio, apresenta maior flexibilidade, porém menor previsibilidade, podendo introduzir ruído na resposta.

A análise empírica, portanto, confirma que, para o conjunto de documentos testados, o método de OCR com Tesseract e regex foi mais eficiente e confiável na extração completa das informações desejadas. O Donut, apesar de funcional em parte dos campos, demonstrou limitações relevantes na consistência das respostas, especialmente na identificação correta do nome do aluno.